تحلیل ریاضی و آماری یکسان‌سازی کدینگ گلوکوزان و زرنام

مدل تطابق، برآورد فاصلهٔ اطمینان، آزمون استقلال، توافق واحد سنجش و سناریوی کاتالوگ نهایی · ۲۲ مهر ۱۴۰۵

۶٫۲٪
نرخ پوشش قطعی+قوی، فاصلهٔ ۹۵٪: ۵٫۸٪ تا ۶٫۶٪

۲۳٫۹٪
سقف پوشش با گروه احتمالی، فاصلهٔ ۹۵٪: ۲۳٫۱٪ تا ۲۴٫۶٪

κ = ۰٫۶۵
ضریب توافق کاپای کوهن برای واحد سنجش

V = ۰٫۱۴۸
کرامر: وابستگی تطابق به خانوادهٔ کالا (p کمتر از 10^{-10})

چکیده

برای هر کالای گلوکوزان، نزدیک‌ترین متریال زرنام با یک امتیاز شباهت ترکیبی پیدا شد و با کنترل اعداد و اسم اصلی کالا در چهار سطح دسته‌بندی شد. نرخ پوشش قطعی **۶٫۲٪** است و حتی اگر همهٔ موارد احتمالی تأیید شوند، از **۲۳٫۹٪** بالاتر نمی‌رود. شکاف اصلی در **واژگان** نیست: ۹۱٫۸٪ کلمات شرح‌های گلوکوزان در زرنام هم به‌کار رفته است. شکاف در **مشخصات عددی** است، یعنی سایز، ابعاد و پارت‌نامبر: در ۴۰٫۴٪ کالاها، بهترین کاندید زرنام عدد متفاوتی دارد. نتیجه این‌که پس از یکسان‌سازی، بین **۹,۷۵۲** تا **۱۲,۰۴۷** کد جدید به Master SAP اضافه می‌شود؛ یعنی رشد ۲۶٫۳٪ تا ۳۲٫۴٪.

۱. تعریف مدل

مجموعهٔ کالاهای گلوکوزان را G و مجموعهٔ متریال‌های یکتای زرنام را Z می‌نامیم. هدف، یافتن تابع نگاشت f است که هر کالای گلوکوزان را به یک متریال زرنام یا به «کد جدید» (∅) ببرد.

```
|G| = 12,980      |Z| = 37,128   (133,724 rows, duplication factor 133,724 / 37,128 = 3.60)
f : G → Z ∪ {∅}

s(g,z) = max( (cos_tfidf + TSR + TSet) / 3 ,  (cos_tfidf + TSR_spec) / 2 )      s ∈ [0,1]
cos_tfidf : char 2–4-gram TF-IDF cosine   TSR / TSet : token-sort / token-set ratio
J_w(g,z)  = |W_g ∩ W_z| / |W_g ∪ W_z|         (key-word Jaccard, fuzzy ≥ 0.85)
ν(g,z)    ∈ {equal, none, subset, oneside, conflict}   (multiset of numbers)

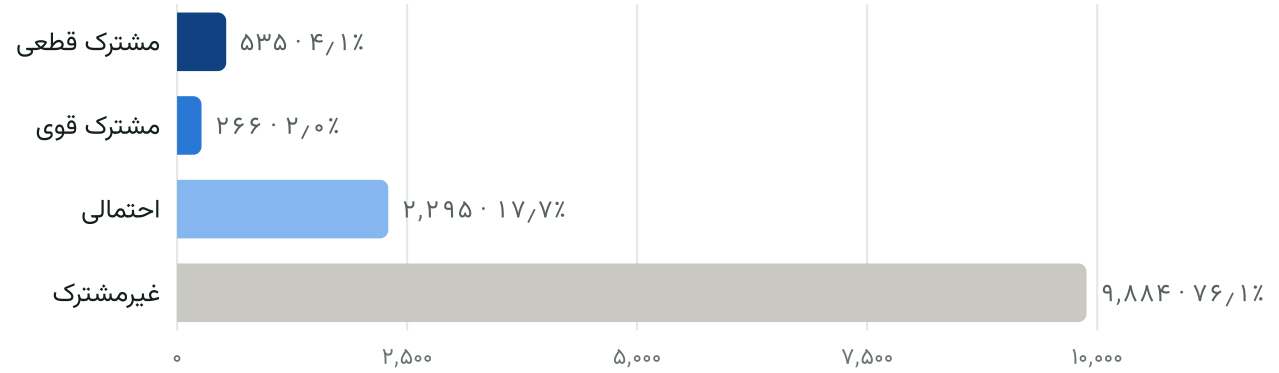
tier(g) = 1  if  norm(g) = norm(z)
        = 2  if  s ≥ 0.85 ∧ J_w ≥ 0.75 ∧ ν ∈ {equal,none} ∧ head(g)≈head(z)
        = 3  if  s ≥ 0.70 ∧ J_w ≥ 0.40 ∧ ν ≠ conflict  (or equivalent relaxed rules)
        = 4  otherwise
```

۲. نرخ پوشش و فاصلهٔ اطمینان

نرخ پوشش نسبتی از کالاهای گلوکوزان است که در زرنام معادل دارند. برای این نسبت، فاصلهٔ اطمینان ویلسون محاسبه شد. این فاصله فقط خطای نمونه‌ای را می‌سنجد و خطای قواعد تطابق را در بر نمی‌گیرد؛ آن خطا در بخش ۸ مدل شده است.

```
p̂₁₂  = (n₁ + n₂) / N = (535 + 266) / 12,980 = 0.0617     95% Wilson CI = [0.0577 , 0.0660]
p̂₁₂₃ = (n₁ + n₂ + n₃) / N = 3,096 / 12,980 = 0.2385    95% Wilson CI = [0.2313 , 0.2459]
p̂₄   = n₄ / N = 9,884 / 12,980 = 0.7615

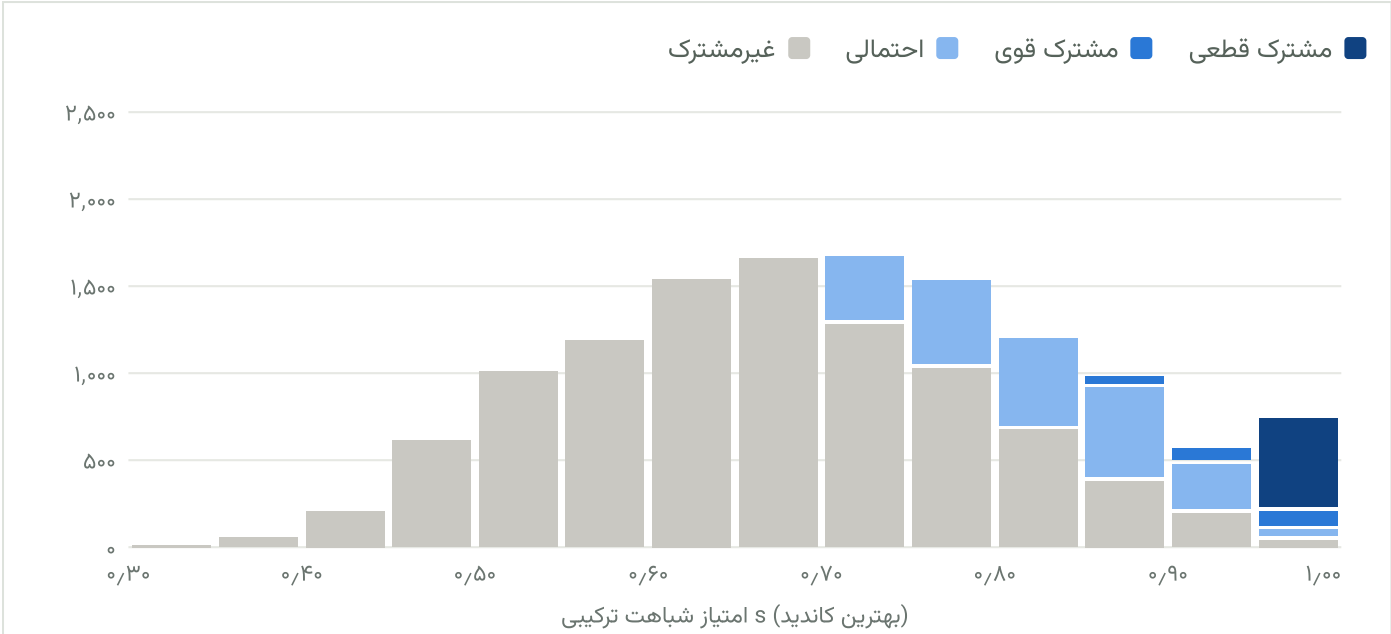
Wilson:  ( p̂ + z²/2n ± z·√( p̂(1−p̂)/n + z²/4n² ) ) / (1 + z²/n) ,   z = 1.96
```



نمودار ۱: تعداد کالا در هر سطح تطابق؛ کل N = ۱۲٬۹۸۰.

۳. توزیع امتیاز شباهت

توزیع امتیاز s برای بهترین کاندید هر کالا تقریباً تک‌قله‌ای است. میانگین آن ۰٫۷۰۹، میانه ۰٫۷۰۶ و انحراف معیار σ = ۰٫۱۴۲ است. همپوشانی دسته‌ها روی محور s نشان می‌دهد که شباهت متنی به‌تنهایی برای تصمیم کافی نیست. برای همین، کنترل اعداد و اسم اصلی کالا لازم بود: کالاهای زیادی با s بالاتر از ۰٫۸ به‌خاطر مغایرت عددی در سطح ۴ مانده‌اند.

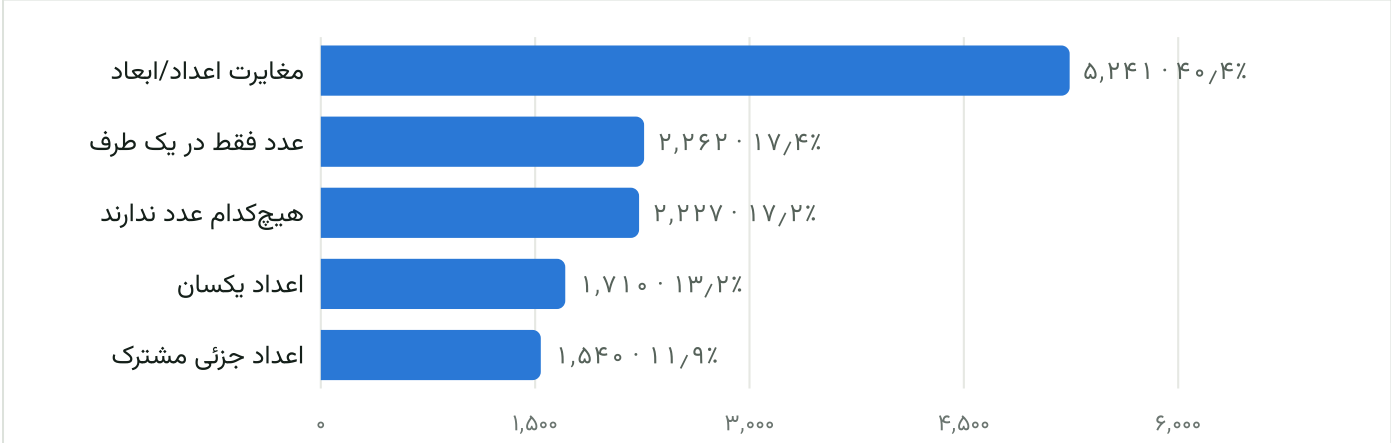


نمودار ۲: هیستوگرام انباشتهٔ امتیاز s با بازه‌های ۰٫۰۵. کالاهای سطح ۱ به‌طور تعریفی s = ۱ دارند.

سطح	n	میانگین s	میانه	σ
مشترک قطعی	۵۳۵	۱٫۰۰۰	۱٫۰۰۰	۰٫۰۰۰
مشترک قوی	۲۶۶	۰٫۹۲۸	۰٫۹۳۳	۰٫۰۳۷
احتمالی	۲,۲۹۵	۰٫۸۲۴	۰٫۸۲۷	۰٫۰۶۸
غیرمشترک	۹,۸۸۴	۰٫۶۶۱	۰٫۶۵۹	۰٫۱۱۸

۴. علت عدم تطابق: مشخصات عددی

۷۵٫۵٪ عنوان‌های گلوکوزان و ۸۰٫۸٪ شرح‌های زرنام دست‌کم یک عدد دارند (سایز، رده، توان، پارت‌نامبر).
نمودار زیر رابطهٔ اعداد هر کالا را با بهترین کاندید زرنامش نشان می‌دهد.



نمودار ۳: سازگاری مجموعهٔ اعداد (۷) میان هر کالای گلوکوزان و بهترین کاندید زرنام.

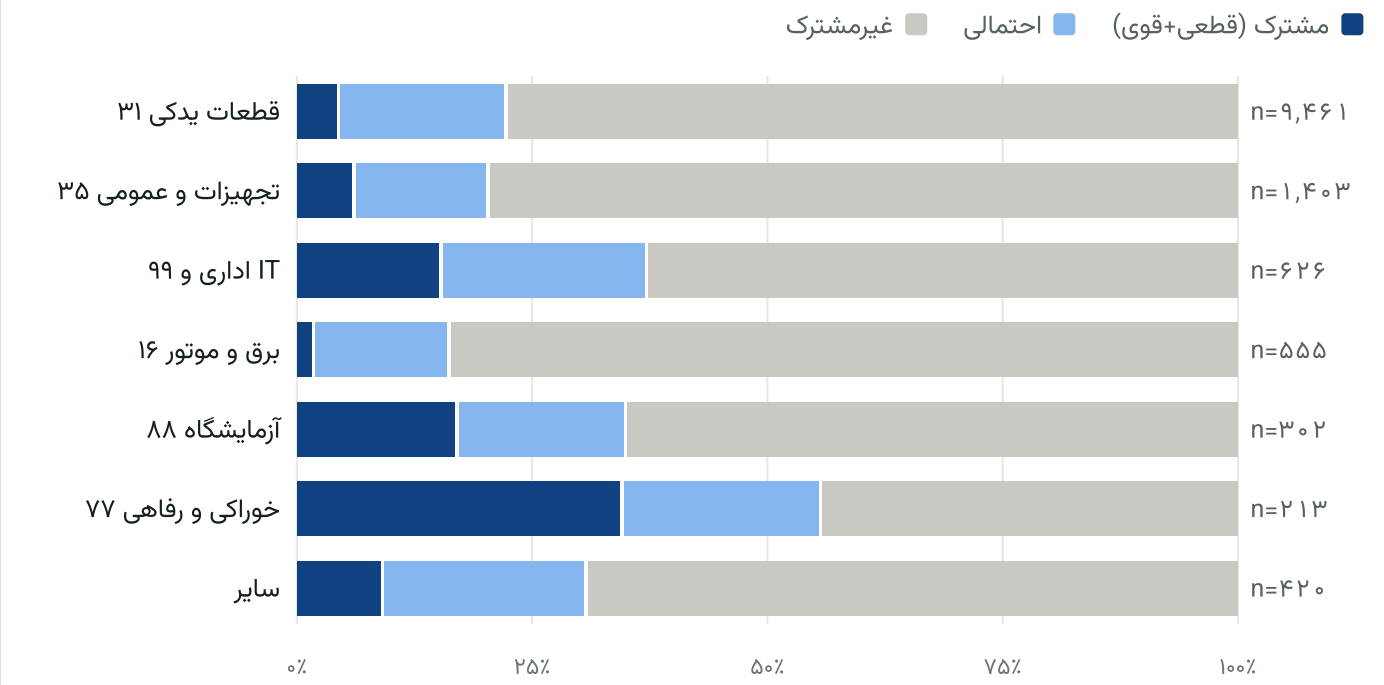
در **۹۷۳** کالای غیرمشترک، شباهت متنی s ≥ ۰٫۸۰ است ولی اعداد فرق دارد؛ در ۵۱۷ مورد حتی s ≥ ۰٫۸۵. این‌ها همان کالا در سایز دیگری هستند، مثل کاسه‌نمد، بلبرینگ یا اتصالات. زرنام خانوادهٔ این کالا را دارد ولی آن سایز را ندارد. در کد جدید باید از همان قالب شرح زرنام استفاده شود.

۵. وابستگی تطابق به نوع کالا (آزمون χ^2)

فرض صفر H_0: «وضعیت تطابق مستقل از خانوادهٔ کد کالاست». جدول توافقی ۷ × ۳ آزمون شد.

```
χ² = Σ (Oᵢⱼ − Eᵢⱼ)² / Eᵢⱼ = 571.7      df = (7−1)(3−1) = 12      p ≈ 1.2e-114
Cramér's V = √( χ² / (N · (min(r,c) − 1)) ) = √( 571.7 / (12,980 × 2) ) = 0.148
standardized residual  rᵢⱼ = (Oᵢⱼ − Eᵢⱼ) / √Eᵢⱼ      |r| > 2  →  significant deviation
```

H_0 با اطمینان کامل رد می‌شود؛ یعنی شانس تطابق به نوع کالا وابسته است. البته ۰٫۱۵ = V یعنی اندازهٔ اثر **ضعیف تا متوسط** است. معنی‌اش این است که تطابق در همهٔ خانواده‌ها پایین است و فقط بعضی از آن‌ها از این سطح عمومی بهترند.



نمودار ۴: ترکیب درصدی وضعیت تطابق در هر خانوادهٔ کد گلوکوزان (پیشوند دو رقمی کد).

خانواده	n	مشترک r	احتمالی r	غیرمشترک r
۳۱ قطعات یدکی	۹,۴۶۱	-۵٫۹۵	+۰٫۳۷	+۱٫۵۲
۳۵ تجهیزات و عمومی	۱,۴۰۳	+۰٫۱۵	-۳٫۰۵	+۱٫۴۳
۹۹ اداری و IT	۶۲۶	+۹٫۳۹	+۲٫۵۰	-۳٫۸۸
۱۶ برق و موتور	۵۵۵	-۳٫۹۷	-۱٫۸۳	+۲٫۰۱
۸۸ آزمایشگاه	۳۰۲	+۷٫۷۳	+۰٫۰۸	-۲٫۲۴
۷۷ خوراکی و رفاهی	۲۱۳	+۱۶٫۷۹	+۱٫۲۰	-۵٫۳۵
سایر	۴۲۰	+۲٫۵۷	+۱٫۹۴	-۱٫۶۷

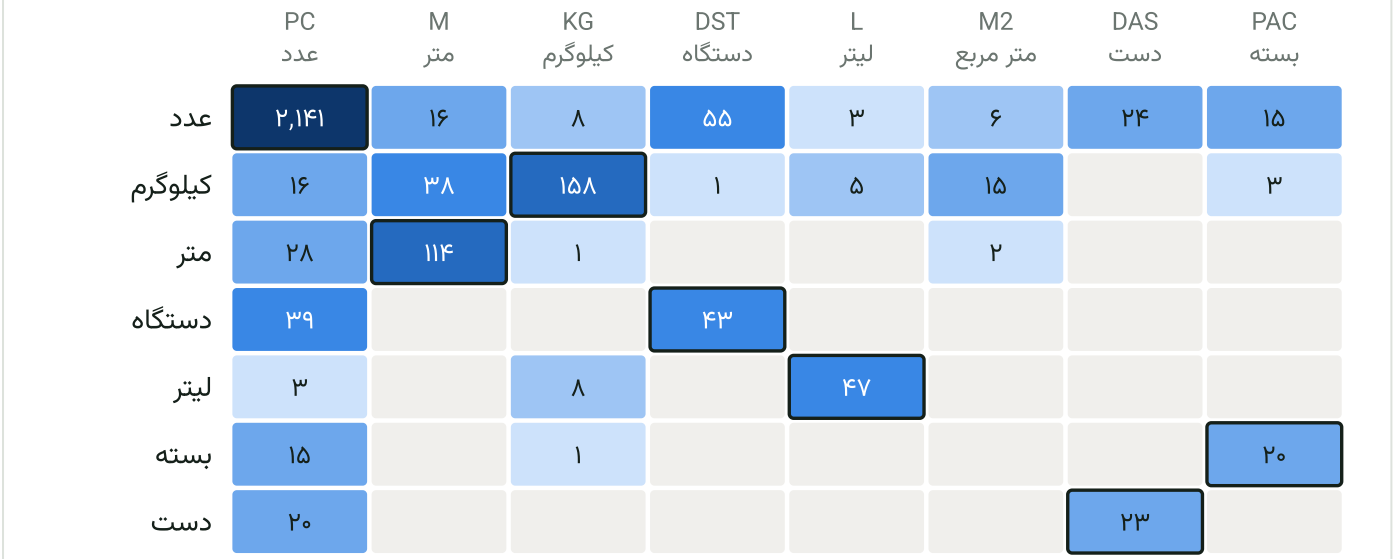
باقیماندهٔ مثبت یعنی تعداد واقعی از مقدار مورد انتظار بیشتر است. اقلام **خوراکی (+۱۶٫۸ = r)**، آزمایشگاهی (+۷٫۷) و اداری (+۹٫۴) خیلی بیشتر از انتظار مشترک‌اند. **قطعات یدکی (-۵٫۹۵)** و برقی (-۳٫۹۷) کمتر از انتظار مشترک‌اند. قطعات یدکی ۷۴٫۲٪ کل کدهای جدید را می‌سازند، پس تمرکز تیم کدینگ باید روی همین خانواده باشد.

۶. توافق واحد سنجش (کاپای کوهن)

برای ۳٬۰۹۶ کالای مشترک و احتمالی، واحد راهکاران به کد SAP نگاشت و با واحد پایهٔ زرنام مقایسه شد. PC و EA یکی در نظر گرفته شدند. توافق ساده بخشی از توافق را که به‌طور تصادفی هم رخ می‌داد در بر دارد؛ کاپا این سهم تصادفی را کنار می‌گذارد.

```
p₀ = observed agreement          = 0.8472      (shared only, n=801: 0.8702)
pₑ = Σₖ p_G(k) · p_Z(k)          = 0.5590      (chance agreement; "piece" dominates)
κ  = (p₀ − pₑ) / (1 − pₑ)        = 0.654       → substantial agreement (Landis–Koch 0.61–0.80)

Shannon entropy of UoM:  H = −Σ pₖ log₂ pₖ
H_G = 1.507 bits (35 units)      H_Z = 1.653 bits (43 units)
```



نمودار ۵: ماتریس توافقی واحد سنجش. سطرها واحد گلوکوزان و ستون‌ها واحد پایهٔ زرنام‌اند. قطر (کادردار) یعنی توافق و خانه‌های بیرون قطر یعنی ضریب تبدیل لازم است. شدت رنگ لگاریتمی است.

κ = ۰٫۶۵ توافق «قابل‌توجه» است، ولی کامل نیست. بیشترین مغایرت‌ها عدد ↔ دستگاه، کیلوگرم ↔ متر و شاخه ↔ متر است. آنتروپی واحدها در هر دو شرکت حدود ۱٫۵ تا ۱٫۷ بیت است، یعنی تنوع واحد در دو شرکت مشابه است و مغایرت از تعریف واحد در سطح کالا می‌آید، نه از تفاوت فهرست واحدها.

۷. شکاف نام‌گذاری

```
Vocabulary Jaccard   J = |V_G ∩ V_Z| / |V_G ∪ V_Z| = 3,323 / 13,082 = 0.254
Token coverage       C = Σ 1[w ∈ V_Z] / |tokens_G|     = 0.918
|V_G| = 4,964   |V_Z| = 11,441
```

شاخص	گلوکوزان	زرنام
میانگین طول شرح (کاراکتر)	۲۶٫۰	۲۷٫۳
سهم شرح‌های بیش از ۴۰ کاراکتر (پس از حذف فاصلهٔ اضافه)	۱۰٫۱٪	۰٫۰٪ (سقف SAP)
سهم شرح‌های دارای فاصلهٔ تکراری	۵۴٫۹٪	۷٫۵٪
سهم شرح‌های دارای ي و ك عربی	۰٫۰٪	۵٫۸٪

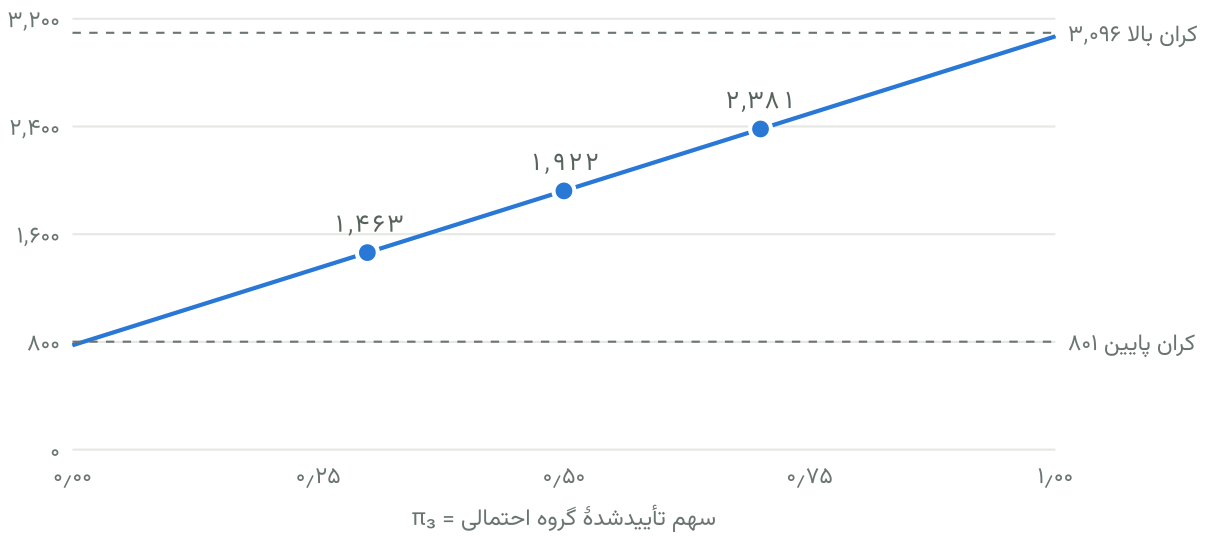
> J = ۰٫۲۵ کم به نظر می‌رسد، ولی C = ۰٫۹۲ نشان می‌دهد ۹۱٫۸٪ کلماتی که گلوکوزان در عمل به‌کار برده در زرنام هم هست. واژگان اضافهٔ زرنام از کاتالوگ بزرگ‌ترش می‌آید. پس دو شرکت به یک زبان کالا را نام می‌برند و تفاوت در **قالب** نوشتن است: ترتیب کلمات، فاصله‌ها، نوشتن اینچ و ابعاد.

۸. مدل سناریو: تعداد قابل اکستند و اندازهٔ کاتالوگ نهایی

اگر π_k دقت سطح k باشد (سهمی از نگاشت‌ها که کارشناس تأیید می‌کند)، تعداد مورد انتظار کالاهای قابل اکستند این است:

```
E[X] = n₁·π₁ + n₂·π₂ + n₃·π₃ ,   π₁ = 1 ,  π₂ ≈ 0.90 (sample) ,  π₃ ∈ [0,1] unknown
E[X] = 535 + 266×0.90 + 2,295×π₃ = 774.4 + 2,295·π₃
π₃ = 0.5  →  E[X] ≈ 1,922   (14.8% of G)

New master records:  N_new = |unique(tier-4 descriptions)| + n₃(1 − π₃)
                     = 9,752 + 2,295(1 − π₃)   ∈ [9,752 , 12,047]
Master growth:       ΔZ / Z = N_new / 37,128 ∈ [26.3% , 32.4%]
Many-to-one compression (tiers 1–2): 801 items → 733 Zarnam codes  (ratio 1.093)
```



نمودار ۶: E[X] بر حسب π_3 با π_2 = ۰٫۹. نوار کم‌رنگ بازهٔ π_2 بین ۰٫۸۵ و ۰٫۹۵ است و خطچین‌ها کران پایین و بالای پوشش‌اند.

> E[X] نسبت به π_3 خطی است و شیب آن n_3 = ۲,۲۹۵ است. یعنی هر ۱۰ واحد درصد دقت بیشتر در بررسی کارشناسی، حدود ۲۳۰ کالای دیگر را قابل اکستند می‌کند. عدم قطعیت π_2 اثر ناچیزی دارد (±۱۳ کالا). پس **بررسی گروه احتمالی مؤثرترین اهرم** برای کاهش کدهای جدید است.

۹. جمع‌بندی ریاضی

1. نرخ پوشش قطعی ۶٫۲٪ است (فاصلهٔ ۹۵٪: ۵٫۸٪ تا ۶٫۶٪) و سقف پوشش ۲۳٫۹٪. در هر سناریو، دست‌کم ۷۶٪ کالاها کد جدید لازم دارند.
2. علت غالب عدم تطابق، مغایرت مشخصات عددی است (۴۰٫۴٪)، نه تفاوت واژگان (پوشش واژگانی ۹۱٫۸٪).
3. تطابق به نوع کالا وابسته است ($\chi^2 = ۵۷۲$، $df = ۱۲$، $V = ۰٫۱۵$). اقلام خوراکی، اداری و آزمایشگاهی سریع اکستند می‌شوند و قطعات یدکی بیشترین کار را دارند.
4. توافق واحد سنجش $\kappa = ۰٫۶۵$ است. حدود ۱۵٫۳٪ کالاهای مشترک و احتمالی ضریب تبدیل یا واحد فرعی لازم دارند.
5. Master SAP بین ۲۶٫۳٪ و ۳۲٫۴٪ بزرگ‌تر می‌شود. هر ۱۰٪ دقت بیشتر در بررسی گروه احتمالی حدود ۲۳۰ کد جدید را حذف می‌کند.

منبع: خروجی کدینگ راهکاران گلوکوزان (۱۲,۹۸۰ کالا) و خروجی SAP زرنام، پلنت ۱۰۰۲ (۳۷,۱۲۸ متریال یکتا). $\pi_2 = ۰٫۹$ از نمونه‌گیری دستی کوچک به دست آمده و π_3 نامعلوم است؛ هر دو فرض‌اند. آمارها روی خروجی خودکار تطابق محاسبه شده‌اند و جزئیات هر کالا در فایل اکسل تحلیل آمده است.